6. Análise Exploratória de Dados e Mineração

> Script: `src/tebd_trab/mineracao.py` · Resultados brutos: `docs/figuras/resultados_mineracao.json`
>
> **Observação:** os dados são **sintéticos** (gerados por `src/tebd_trab/gerar_dados.py`) e simulam a rede de ônibus de Salvador entre jan/2022 e nov/2026. Os padrões encontrados foram embutidos na simulação de forma plausível; o objetivo é demonstrar o método, que funciona da mesma forma com dados reais de GPS e bilhetagem.

6.1. Definição do problema

Pergunta de negócio: *Quais viagens têm alto risco de sair com atraso relevante, e o que explica esse risco?*

O atraso é a principal reclamação do usuário de transporte público e afeta diretamente a Meta 11.2 da ODS 11 (transporte seguro, acessível e sustentável). Se a operação souber **antes** da viagem quais combinações de linha, horário, veículo e época do ano têm maior risco, ela pode agir preventivamente: reforçar a frota, trocar o veículo por um mais novo, ajustar o quadro de horários ou priorizar faixas exclusivas.

Formulação como tarefa de mineração: classificação binária supervisionada.

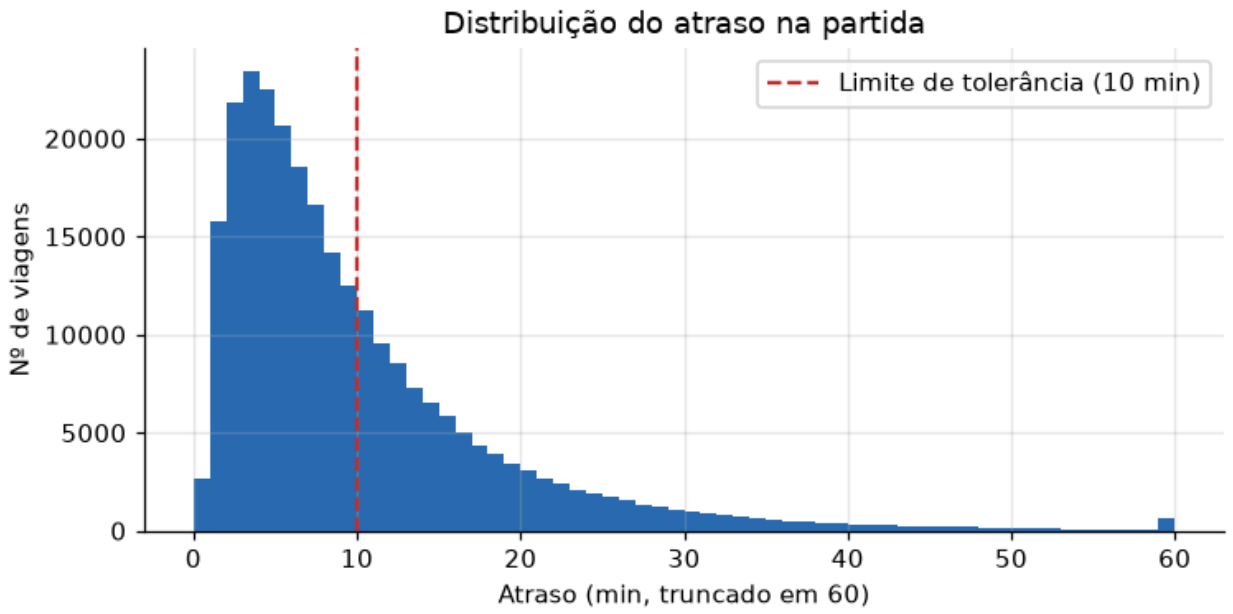
- **Variável-alvo:** `flag_atraso` = 1 se `atraso_minutos > 10` (tolerância adotada), 0 caso contrário.
- **Atributos preditores:** somente informações **conhecidas antes da viagem**: hora programada, horário de pico, fim de semana, período chuvoso, período escolar, zona da linha, tipo de serviço, extensão da linha, tipo de combustível e idade do veículo.
- **Excluídos de propósito:** lotação, tempo de viagem e emissão. Eles só são conhecidos **depois** da viagem e causariam vazamento de dados (*data leakage*).

6.2. Análise exploratória (EDA)

Base analisada: **263.879 viagens** extraídas do Data Warehouse (`fato_viagens_transporte` + dimensões).

Indicador	Valor
Viagens com atraso > 10 min	**31,8%**
Taxa de atraso: fora do pico → no pico	22,9% → **47,4%**
Taxa de atraso: período seco → chuvoso (abr-jul)	28,6% → **37,8%**
Taxa de atraso: dia útil → fim de semana	34,7% → 19,1%
Taxa de atraso: Orla / Miolo / Subúrbio	14,3% / 36,5% / **52,1%**
Idade média da frota: Orla / Miolo / Subúrbio	3,4 / 7,4 / **13,3 anos**
Taxa de atraso: Elétrico / Híbrido / GNV / Diesel	12,4% / 27,8% / 28,7% / **36,7%**

Distribuição do atraso. A distribuição é assimétrica à direita: a maioria das viagens sai com poucos minutos de atraso, mas há uma cauda longa de atrasos de 20 a 40 minutos.



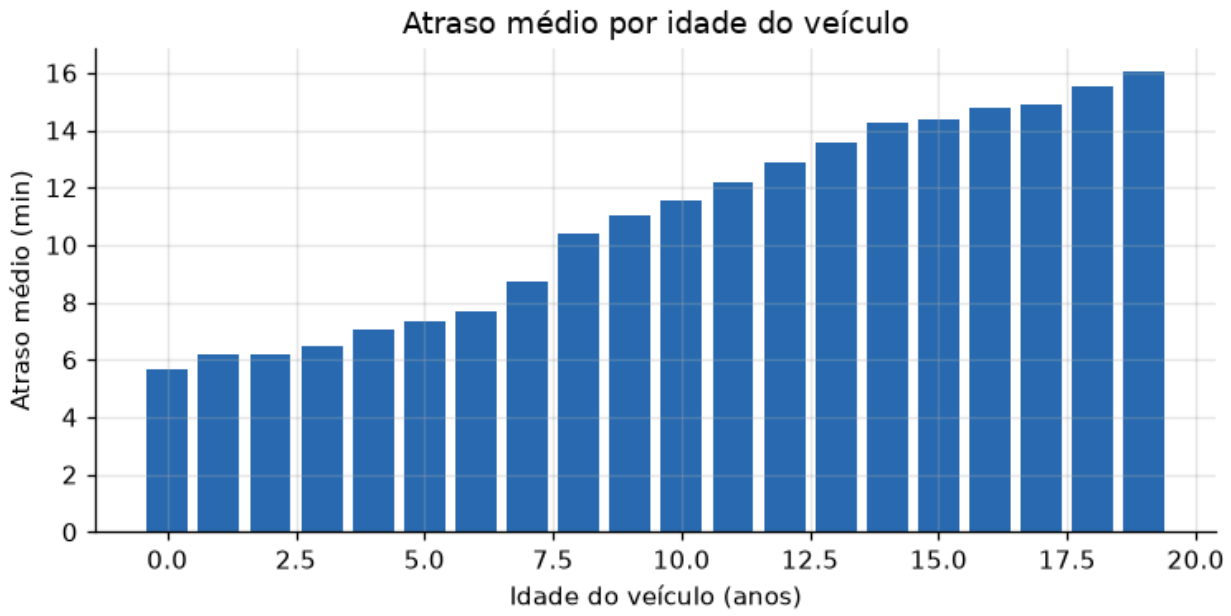
Distribuição do atraso

Horário e zona. Os picos (7h-9h e 17h-19h) praticamente dobram o atraso médio em todas as zonas. O Subúrbio fica sistematicamente acima das outras zonas em qualquer horário.

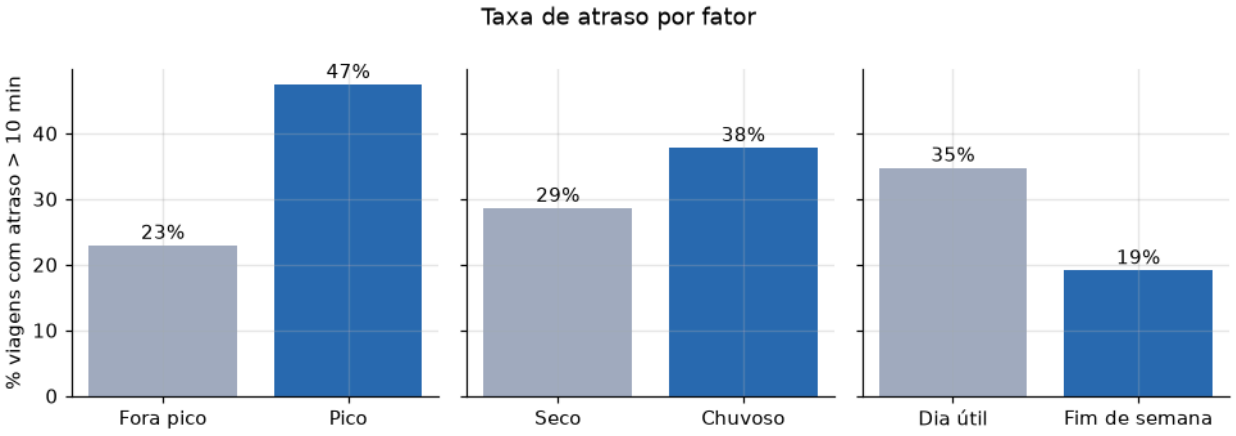


Atraso por hora e zona

Idade do veículo. O atraso médio cresce com a idade do veículo. Isso é coerente com mais quebras e manutenção corretiva em ônibus antigos.

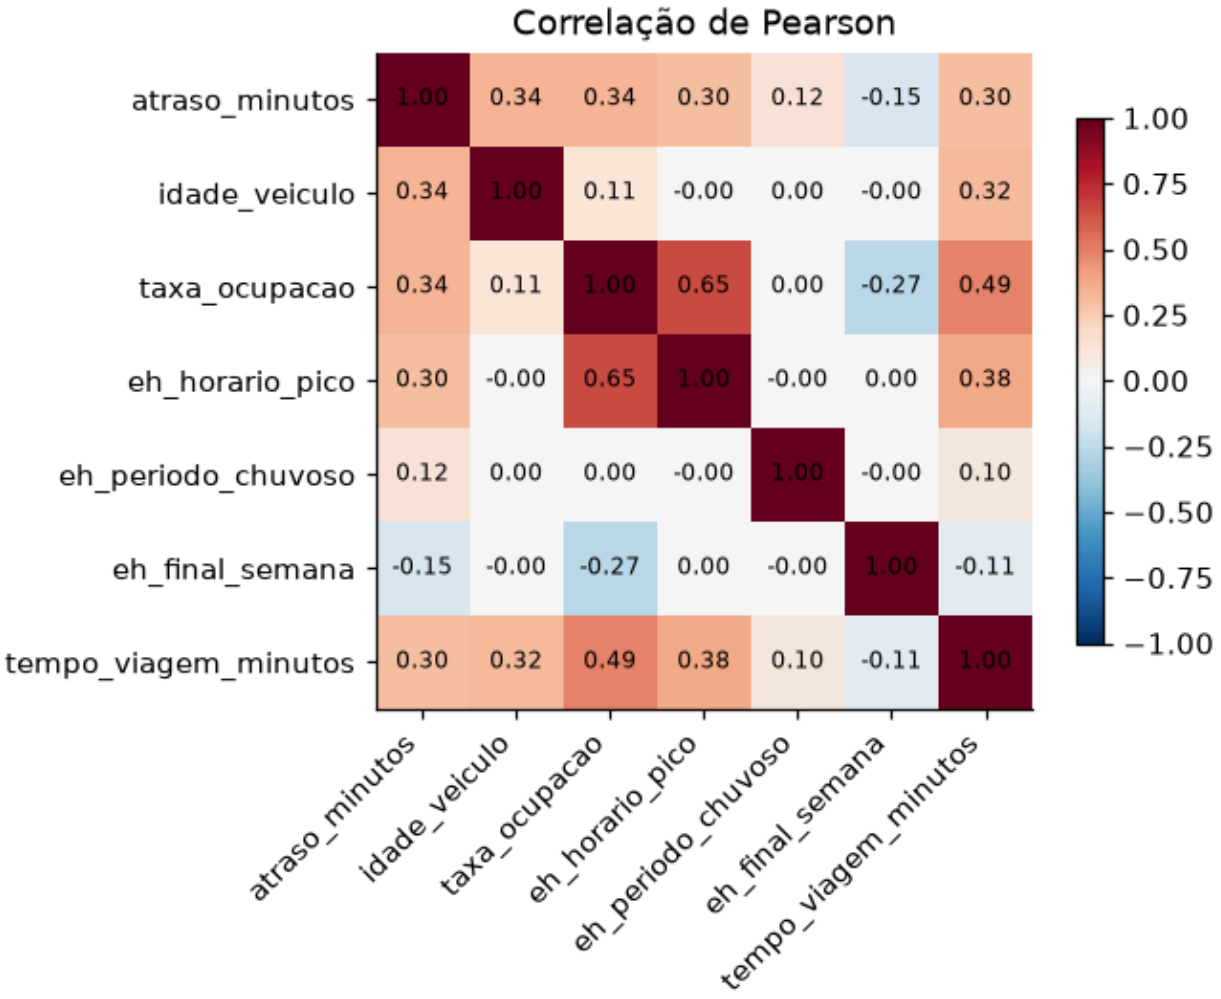


Atraso por idade



Taxa de atraso por fator

Correlações com `atraso_minutos`. Idade do veículo (0,34), taxa de ocupação (0,34), horário de pico (0,30), período chuvoso (0,12) e fim de semana (−0,15). Nenhuma correlação isolada é forte, o que indica que o atraso resulta da **combinação** de fatores. Um modelo de árvore captura bem esse tipo de interação.



Correlação

6.3. Método: Árvore de Decisão (CART)

Como funciona. A árvore de decisão divide os dados em grupos cada vez mais homogêneos, fazendo perguntas do tipo “o atributo X é menor ou igual a v?”. Em cada nó, o algoritmo CART (implementado no `scikit-learn`) testa todas as divisões possíveis e escolhe a que mais reduz a **impureza de Gini**:

\[Gini = 1 - \sum_{k} p_k^2\]

em que \(p_k\) é a proporção de viagens da classe *k* no nó. Um nó só com viagens atrasadas tem Gini = 0 (puro). As folhas finais dão a classe prevista e a proporção de atrasos daquele grupo.

Por que este método.

1. **Interpretabilidade:** cada caminho da raiz até uma folha é uma regra “SE … ENTÃO …” que o gestor entende sem conhecer estatística. Isso é essencial para justificar uma decisão pública.
2. Lida com atributos numéricos e categóricos e com **interações não lineares** (por exemplo, pico *e* Subúrbio), sem precisar normalizar os dados.
3. Indica a **importância de cada atributo**, o que orienta onde investir.

Configuração e validação.

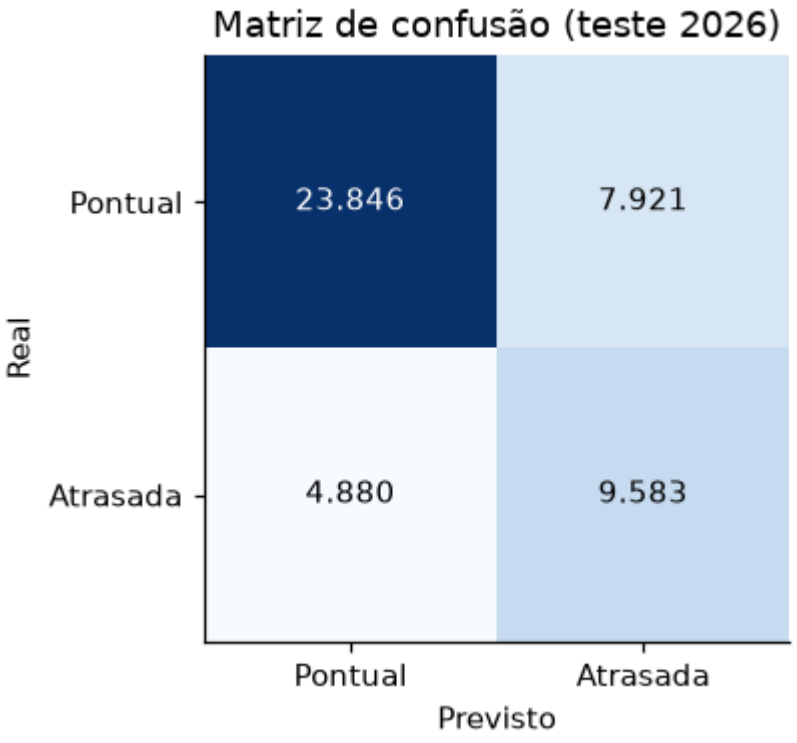
Parâmetro	Valor	Motivo
`max_depth`	4	Árvore pequena, legível e menos sujeita a sobreajuste.
`min_samples_leaf`	500	Cada regra se apoia em pelo menos 500 viagens.
`class_weight`	`balanced`	Só 32% das viagens atrasam; sem balanceamento, o modelo tenderia a prever sempre “pontual”.
Divisão treino/teste	**Temporal**: treino 2022-2025 (217.649 viagens), teste 2026 (46.230)	Simula o uso real: aprende com o passado e prevê o futuro.

Categorias como zona e combustível foram transformadas em variáveis binárias (*one-hot encoding*).

6.4. Resultados

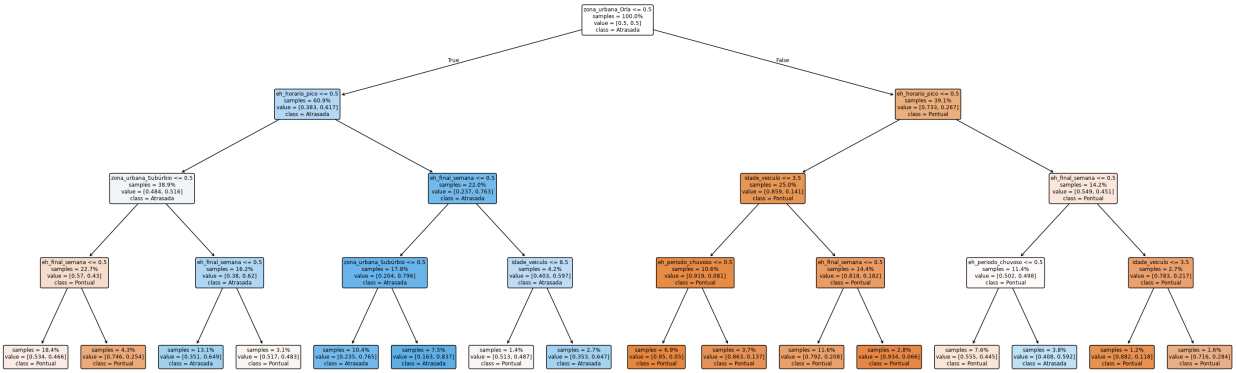
Métrica (teste 2026)	Valor
Acurácia do modelo	**72,3%**
Acurácia de referência (sempre “pontual”)	68,7%
Precisão (classe “Atrasada”)	54,7%
Revocação (classe “Atrasada”)	**66,3%**
F1 (classe “Atrasada”)	60,0%
AUC-ROC	**0,781**

A acurácia pouco acima da referência não é a métrica que importa aqui: a referência nunca acerta um atraso. O modelo **identifica 2 de cada 3 viagens que vão atrasar** (revocação de 66%). O AUC de 0,78 indica boa capacidade de ordenar as viagens por risco. Para uso operacional (priorizar reforços), um falso alarme custa pouco e um atraso não previsto custa caro, então dar prioridade à revocação é uma escolha consciente.



Matriz de confusão

A árvore obtida

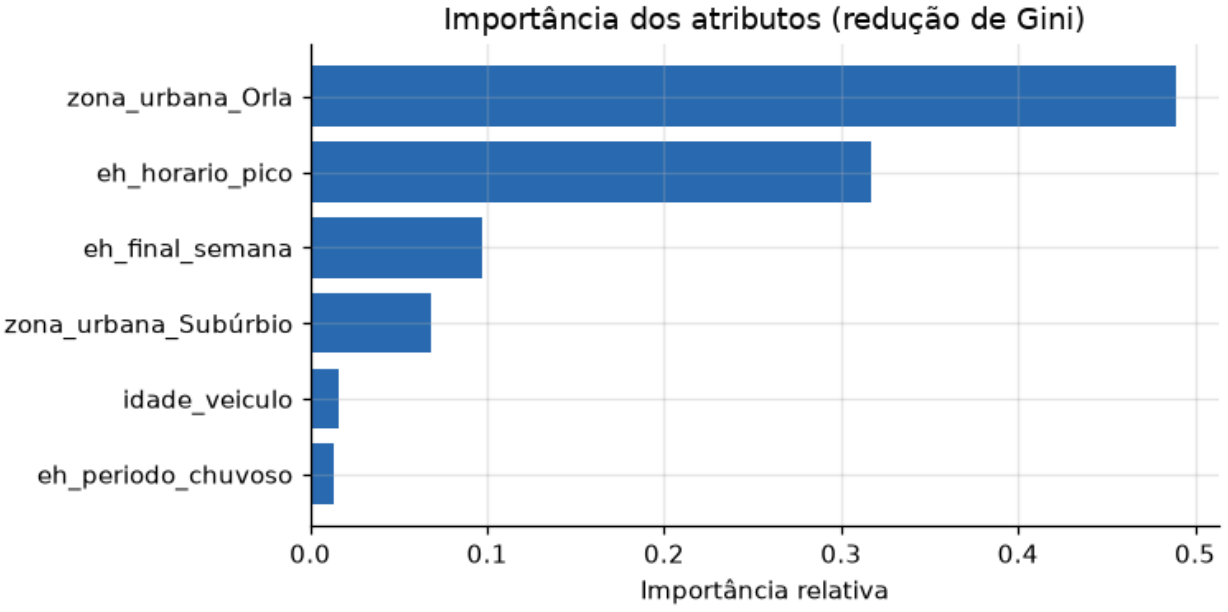


Árvore de decisão

Principais regras extraídas (lidas da árvore; “% atrasadas” é a proporção na folha, ponderada pelo balanceamento de classes):

1. **SE** a linha **não é da Orla E** é **horário de pico E** é **dia útil** → **Atrasada** (76,5% no Miolo e 83,7% no Subúrbio). É o grupo mais crítico: Miolo e Subúrbio no pico dos dias úteis.
2. **SE** a linha é do **Subúrbio E** fora do pico **E** dia útil → **Atrasada** (64,9%). No Subúrbio, até o horário normal é problemático.
3. **SE** a linha é da **Orla E** pico **E período chuvoso** → **Atrasada** (59,2%). A chuva derruba a pontualidade mesmo na zona mais bem servida.
4. **SE** fim de semana no pico **E** veículo com **mais de 8 anos** → **Atrasada** (64,7%). Com o veículo mais novo, a mesma situação é classificada como pontual.
5. **SE** a linha é da **Orla E** fora do pico **E** veículo com **até 3 anos** → **Pontual** (apenas 5,0% a 13,7% de atrasos).

Importância dos atributos



Importância

Atributo	Importância
Zona = Orla	0,489

Atributo	Importância
Horário de pico	0,317
Fim de semana	0,097
Zona = Subúrbio	0,068
Idade do veículo	0,016
Período chuvoso	0,013

A zona da linha aparece como o fator mais importante, mas **zona e idade da frota estão fortemente associadas**: o Subúrbio roda com veículos de 13,3 anos em média, contra 3,4 na Orla. Parte do “efeito zona” é, na verdade, efeito da frota antiga e da infraestrutura viária pior da periferia. Essa é uma questão de **equidade** (inclusão social, ODS 11).

Uso prático: risco previsto no pico de 2026

Linha	Risco previsto (score)	Taxa real de atraso
L303 Plataforma - Campo Grande	80,2	71,2%
L302 Periperi - Lapa	79,9	68,4%
L305 Paripe - Caminho das Árvores	79,9	68,4%
L304 Fazenda Coutos - Lobato	79,8	65,5%
L301 Paripe - Comércio	79,7	69,0%

As cinco linhas de maior risco são todas do Subúrbio, e o ranking previsto bate com o ranking real. O score fica acima da taxa real por causa do balanceamento de classes; ele deve ser usado para **ordenar** prioridades, não como probabilidade calibrada.

6.5. Conclusões para a tomada de decisão

1. **Renovar a frota do Subúrbio** é a ação de maior impacto: ataca ao mesmo tempo atraso, emissão de CO_2 e desigualdade territorial.
2. **Faixas exclusivas e reforço de frota nos picos** para as linhas do Miolo e do Subúrbio.
3. **Plano de contingência para o período chuvoso** (abr-jul): quadro de horários com folga e monitoramento de pontos de alagamento.
4. Usar o modelo semanalmente para **gerar a lista de viagens de alto risco** e alocar os veículos mais novos nelas.

Essas conclusões alimentam o Plano de Ação 5W2H (`docs/10_plano_acao_5w2h.md`).

Limitações: os dados são sintéticos; o modelo não usa trânsito em tempo real, acidentes ou eventos; a árvore rasa privilegia a interpretação em vez do desempenho máximo. Modelos como *Random Forest* podem aumentar o AUC, mas perdem legibilidade.